3.2. Thiết kế tích hợp AI

3.2.1. Kiến trúc tổng thể và nguyên lý tích hợp AI

Nhằm hỗ trợ bệnh viện điều phối nguồn máu và giúp người dân tiếp cận thông tin hiến máu thuận tiện hơn, hệ thống được tích hợp ba chức năng trí tuệ nhân tạo: gợi ý người hiến máu phù hợp, dự báo nhu cầu sử dụng máu và chatbot tư vấn hiến máu. Do mỗi chức năng giải quyết một dạng bài toán khác nhau, hệ thống không dùng chung một mô hình mà lựa chọn kỹ thuật phù hợp cho từng chức năng như trình bày ở Bảng 3.1.

Bảng 3.1. Các chức năng AI và kỹ thuật sử dụng

Chức năng	Dạng bài toán	Kỹ thuật sử dụng
Gợi ý người hiến máu	Xếp hạng theo xác suất nhận lời	Lọc bằng luật, sau đó xếp hạng bằng hồi quy logistic hoặc XGBoost
Dự báo nhu cầu sử dụng máu	Dự báo chuỗi thời gian dạng số đếm	XGBoost với hàm mục tiêu Poisson, so sánh với trung bình 28 ngày
Chatbot tư vấn hiến máu	Hỏi đáp bằng ngôn ngữ tự nhiên	RAG (truy xuất BM25) kết hợp mô hình ngôn ngữ lớn Qwen3 chạy qua Ollama

Các công nghệ AI chính được sử dụng gồm nền tảng Ollama để chạy mô hình ngôn ngữ ngay trên máy chủ của hệ thống, mô hình ngôn ngữ lớn mã nguồn mở Qwen3 cho chatbot và thư viện học máy XGBoost cho các chức năng dự báo, gợi ý (Hình 3.1).



Hình 3.1. Các công nghệ AI được sử dụng trong hệ thống

Toàn bộ hệ thống được triển khai bằng Docker, gồm các thành phần được mô tả ở Bảng 3.2. Cách triển khai tại chỗ giúp dữ liệu người dùng không phải gửi ra dịch vụ bên ngoài, đồng thời không phát sinh chi phí sử dụng API.

Bảng 3.2. Các thành phần triển khai liên quan đến AI

Thành phần	Vai trò
web (Django)	Xử lý giao diện và nghiệp vụ; chạy chatbot, xếp hạng người hiến và đọc kết quả dự báo
scheduler	Tác vụ định kỳ: dự báo nhu cầu mỗi đêm, so sánh với thực tế, huấn luyện lại mô hình khi có lý do
db (PostgreSQL 16)	Lưu dữ liệu nghiệp vụ, sổ kho, lịch sử kêu gọi, kết quả dự báo (forecast_snapshots) và hội thoại
ollama	Chạy mô hình ngôn ngữ Qwen3; chỉ nhận kết nối từ mạng nội bộ Docker, không mở cổng ra ngoài
Thư mục mô hình	Lưu các phiên bản mô hình học máy đã huấn luyện, kèm kết quả kiểm tra của từng phiên bản

Việc tích hợp AI tuân theo các nguyên tắc sau. Thứ nhất, AI chỉ đóng vai trò hỗ trợ, quyết định cuối cùng thuộc về con người: AI chỉ sắp xếp danh sách người hiến, chỉ cảnh báo thiếu máu, còn việc gửi lời mời, tạo đợt hiến hay xin hỗ trợ liên viện do nhân viên bệnh viện thực hiện. Thứ hai, AI chỉ được đọc dữ liệu, không được tạo hay sửa dữ liệu nghiệp vụ, và dữ liệu cá nhân chỉ được truy cập theo đúng tài khoản đang đăng nhập. Thứ ba, các điều kiện an toàn như nhóm máu, độ tuổi, khoảng cách giữa hai lần hiến luôn được kiểm tra bằng luật cố định trước khi đến AI. Thứ tư, hệ thống luôn có cơ chế fallback: khi AI gặp lỗi hoặc chưa đủ dữ liệu, hệ thống tự chuyển về phương án không dùng AI để người dùng vẫn nhận được kết quả. Cuối cùng, mô hình học máy chỉ được đưa vào sử dụng khi đã chứng minh tốt hơn phương án đơn giản trên dữ liệu kiểm tra.

3.2.2. Thiết kế quy trình xử lý tri thức

Tri thức trong hệ thống gồm hai nguồn: tri thức chuyên môn về hiến máu phục vụ chatbot và tri thức rút ra từ dữ liệu vận hành phục vụ các mô hình dự báo, gợi ý. Quy trình xử lý hai nguồn tri thức này được tóm tắt ở Bảng 3.3.

Bảng 3.3. Quy trình xử lý hai nguồn tri thức

Bước	Tri thức chuyên môn (chatbot)	Tri thức từ dữ liệu vận hành (dự báo, gợi ý)
Nguồn	16 tài liệu đã duyệt, có nguồn, phiên bản, ngày duyệt	Sổ kho, yêu cầu cần máu đã xác minh, lịch sử kêu gọi

Bước	Tri thức chuyên môn (chatbot)	Tri thức từ dữ liệu vận hành (dự báo, gợi ý)
Chuẩn bị	Chuẩn hóa chữ thường không dấu, bỏ từ dừng, tách từ đơn và cụm hai từ	Tạo đặc trưng chỉ từ dữ liệu có trước thời điểm cần dự đoán; thiếu dữ liệu thật thì dùng dữ liệu mô phỏng
Lập chỉ mục / huấn luyện	Lập chỉ mục BM25, tiêu đề và từ khóa tính gấp ba lần	Huấn luyện mô hình, kiểm tra theo thời gian so với phương án đơn giản
Sử dụng	Truy xuất tối đa 3 tài liệu làm ngữ cảnh cho câu trả lời	Chỉ phiên bản qua chốt chặn mới được dùng
Cập nhật	Sửa nội dung, tăng phiên bản, duyệt lại	Theo dõi sai số thực tế, học lại khi có lý do, giữ các phiên bản cũ

Tri thức chuyên môn được tổ chức thành một kho gồm 16 tài liệu đã được duyệt, bao gồm các chủ đề như điều kiện hiến máu, khoảng cách giữa hai lần hiến, chuẩn bị trước khi hiến, chăm sóc sau khi hiến, các loại chế phẩm máu và hướng dẫn sử dụng hệ thống. Mỗi tài liệu đều ghi rõ nguồn tham khảo, số phiên bản và ngày duyệt. Khi cần cập nhật, người quản lý sửa nội dung, tăng số phiên bản và cập nhật ngày duyệt, nhờ đó chatbot luôn trả lời dựa trên nội dung đã được kiểm duyệt. Các con số phụ thuộc cấu hình như số ngày nghỉ tối thiểu hay độ tuổi hiến máu không được ghi cố định mà lấy trực tiếp từ bảng system_settings, vì vậy khi quản trị viên thay đổi cấu hình thì câu trả lời của chatbot cũng thay đổi theo.

Để tìm tài liệu phù hợp với câu hỏi, hệ thống chuẩn hóa văn bản về dạng chữ thường không dấu, loại bỏ các từ không mang nghĩa như “tôi”, “có”, “không”, sau đó tách thành từ đơn và cụm hai từ. Tiêu đề và từ khóa của tài liệu được tăng trọng số gấp ba lần so với phần nội dung. Mức độ liên quan giữa câu hỏi và tài liệu được tính bằng thuật toán BM25:

$$score(d,q) = \sum_{t \in q} IDF(t) \cdot \frac{f(t,d) \cdot (k_1 + 1)}{f(t,d) + k_1 \cdot \left(1 - b + b \cdot \frac{|d|}{avgdl}\right)} \qquad (3.1)$$

Công thức (3.1) này để tính điểm liên quan của tài liệu d đối với câu hỏi q.

Trong đó f(t, d) là số lần từ t xuất hiện trong tài liệu d, |d| là độ dài tài liệu, avgdl là độ dài trung bình của các tài liệu, k_1 = 1,4 và b = 0,6 là các tham số điều chỉnh. Thành

phần IDF(t) thể hiện mức độ hiếm của từ t, từ càng ít tài liệu chứa thì càng có giá trị phân biệt:

$$IDF(t) = ln\left(1 + \frac{N - n(t) + 0{,}5}{n(t) + 0{,}5}\right) \quad (3.2)$$

Công thức (3.2) này để tính trọng số của từ t, trong đó N là tổng số tài liệu và n(t) là số tài liệu chứa từ t.

Hệ thống chọn tối đa ba tài liệu có điểm cao nhất làm ngữ cảnh cho câu trả lời. Nếu không có tài liệu nào đạt ngưỡng tối thiểu, chatbot trả lời rằng chưa có thông tin thay vì để mô hình tự suy diễn. Đề tài lựa chọn BM25 thay vì tìm kiếm bằng vector ngữ nghĩa vì kho tri thức có quy mô nhỏ, các câu hỏi về hiến máu thường chứa từ khóa rõ ràng, đồng thời BM25 cho kết quả ổn định, dễ kiểm thử và không cần thêm mô hình tạo vector. Khi kho tài liệu mở rộng, hệ thống có thể kết hợp thêm tìm kiếm vector để hiểu các câu hỏi diễn đạt khác từ ngữ.

Đối với tri thức từ dữ liệu vận hành, hệ thống không yêu cầu nhập liệu riêng mà tự rút ra từ dữ liệu nghiệp vụ hằng ngày. Dữ liệu dự báo được lấy từ sổ kho (bảng stock_txns) và các yêu cầu cần máu đã xác minh; dữ liệu gợi ý người hiến được lấy từ lịch sử các lần kêu gọi và kết quả phản hồi của người hiến. Khi dữ liệu thực tế chưa đủ, hệ thống sinh dữ liệu mô phỏng để mô hình vẫn hoạt động được và tự chuyển sang dữ liệu thật khi đã đủ. Mỗi lần huấn luyện tạo ra một phiên bản mô hình mới, phiên bản này chỉ được sử dụng khi vượt qua bước kiểm tra so với phương án đơn giản, đồng thời các phiên bản cũ vẫn được lưu lại để quản trị viên có thể khôi phục khi cần.

3.2.3. Thiết kế các luồng xử lý chuyên biệt

3.2.3.1. Luồng xử lý AI gợi ý người hiến máu phù hợp

Khi bệnh viện thiếu một nhóm máu, nhân viên cần xác định nên gửi lời kêu gọi đến những người hiến nào. Việc mời quá nhiều người gây làm phiền, trong khi mỗi người chỉ được mời một số lần giới hạn, do đó hệ thống cần ưu tiên những người có khả năng nhận lời cao nhất. Bài toán được xây dựng thành bài toán dự đoán xác suất một người hiến nhận lời, nghĩa là đăng ký đợt hiến hoặc đến hiến tại bệnh viện trong vòng 7 ngày sau khi được mời.

Đề tài không sử dụng phương pháp lọc cộng tác thường thấy ở các hệ thống gợi ý sản phẩm, vì mỗi lời kêu gọi là một sự kiện mới chưa có ai phản hồi, đồng thời mỗi người chỉ hiến tối đa khoảng bốn lần một năm nên dữ liệu tương tác rất thưa.

Luồng xử lý gồm hai tầng. Tầng thứ nhất là lọc bằng luật, chỉ giữ lại những người đúng nhóm máu, trong độ tuổi hiến, đã đủ thời gian nghỉ kể từ lần hiến trước, không bị mời quá dày và nằm trong bán kính đã chọn. Tầng thứ hai là xếp hạng bằng mô hình học máy: mô hình chỉ sắp xếp lại thứ tự các ứng viên đã qua bước lọc, không thêm hay loại bỏ người nào.

Mỗi ứng viên được mô tả bằng các đặc trưng tính tại thời điểm gửi lời mời như Bảng 3.4. Hệ thống không sử dụng tuổi và giới tính làm đặc trưng để tránh phân biệt người hiến.

Bảng 3.4. Các đặc trưng đầu vào của mô hình gợi ý người hiến

Nhóm đặc trưng	Đặc trưng
Khoảng cách	Khoảng cách từ bệnh viện đến nơi người hiến từng hiến gần nhất
Lịch sử hiến máu	Số ngày từ lần hiến gần nhất; số lần đã hiến; nhóm máu đã được xét nghiệm; đã từng hiến tại bệnh viện này
Mức độ tin cậy	Số lần hẹn trước đây; tỷ lệ đến đúng hẹn khi đã đăng ký
Phản hồi kêu gọi	Số lời kêu gọi trước đây; tỷ lệ đã nhận lời; số lời kêu gọi đã nhận trong 90 ngày
Hoàn cảnh lời mời	Kêu gọi khẩn hay thường; có kèm đợt hiến cụ thể; gửi vào cuối tuần; giờ gửi

Mô hình hồi quy logistic tính xác suất nhận lời theo công thức:

$$p = \frac{1}{1 + e^{-\left(w_0 + \sum_{j=1}^{n} w_j x_j\right)}} \tag{3.3}$$

Công thức (3.3) này để tính xác suất người hiến nhận lời dựa trên các đặc trưng x_1, x_2, …, x_n.

Trong đó w_j là trọng số mà mô hình học được từ dữ liệu, thể hiện mức độ ảnh hưởng của từng đặc trưng. Bên cạnh hồi quy logistic, hệ thống huấn luyện thêm mô hình XGBoost có khả năng học các mối quan hệ phức tạp hơn giữa các yếu tố, sau đó so sánh cả hai mô hình với cách chấm điểm theo luật đang sử dụng.

Các mô hình được đánh giá trên những lần kêu gọi ở giai đoạn sau mà mô hình chưa từng thấy, với chỉ số chính là tỷ lệ người nhận lời trong 10 người đứng đầu danh sách. Mô hình chỉ được đưa vào sử dụng khi số người nhận lời nhiều hơn cách chấm điểm luật một cách chắc chắn về mặt thống kê, tức cận dưới của khoảng tin cậy 95% phải lớn hơn 0.

Do hệ thống mới triển khai chưa có đủ lịch sử kêu gọi thực tế, dữ liệu mô phỏng được sinh với 5 bệnh viện và 3.000 người hiến trong 18 tháng, trong đó khả năng nhận lời của mỗi người phụ thuộc vào khoảng cách, thời điểm nhận lời mời, số lần đã bị kêu gọi và mức độ nhiệt tình riêng của từng người. Các tham số mô phỏng là giả định và được ghi rõ trong mã nguồn. Kết quả trên dữ liệu mô phỏng gồm 556 lần kêu gọi và 13.900 lời mời được trình bày ở Bảng 3.5.

Chỉ số AUC thể hiện khả năng mô hình xếp một người có nhận lời lên trên một người không nhận lời, giá trị 0,5 tương ứng với việc sắp xếp ngẫu nhiên và càng gần 1 càng tốt. Khoảng tin cậy 95% được ước lượng bằng phương pháp bootstrap: lấy mẫu lại ngẫu nhiên các lần kêu gọi 2.000 lần để xác định phần chênh lệch giữa mô hình và cách chấm điểm luật có ổn định hay chỉ do ngẫu nhiên.

Bảng 3.5. So sánh các cách xếp hạng người hiến (dữ liệu mô phỏng, 278 lần kêu gọi kiểm tra)

Cách xếp hạng	Nhận lời trong 10 người đầu	Số người nhận lời hơn chấm điểm luật mỗi lần (KTC 95%)	AUC
Chấm điểm luật	38,7%	—	0,710
Hồi quy logistic	**40,1%**	**+0,14 (+0,03 → +0,26)**	**0,746**
XGBoost	39,1%	+0,04 (−0,08 → +0,17)	0,733

Mô hình hồi quy logistic đạt tỷ lệ nhận lời 40,1% trong 10 người đầu, cao hơn mức 38,7% của cách chấm điểm luật với khoảng tin cậy hoàn toàn dương, nên được hệ thống lựa chọn. Mô hình XGBoost chưa vượt trội một cách chắc chắn do khoảng tin cậy còn chứa giá trị 0. Mức cải thiện còn khiêm tốn vì cách chấm điểm luật vốn đã dựa trên các yếu tố hợp lý; hiệu quả thực tế sẽ được đo lại khi hệ thống có lịch sử kêu gọi thật.

Khi nhân viên mở chức năng "Gợi ý người hiến", hệ thống lọc ứng viên bằng luật, tính xác suất nhận lời cho từng người và sắp xếp danh sách. Mỗi người hiến được hiển thị bằng mã ẩn danh kèm khả năng nhận lời và các yếu tố ảnh hưởng chính, nhân viên không xem được tên hay số điện thoại. Mức độ ảnh hưởng của mỗi yếu tố được tính

bằng tích giữa trọng số w_j và giá trị đặc trưng tương ứng trong công thức (3.3); ba yếu tố có ảnh hưởng lớn nhất được hiển thị kèm chiều tác động làm tăng hoặc giảm khả năng nhận lời. Một phần nhỏ vị trí trong danh sách được dành cho người hiến mới để họ cũng có cơ hội được mời. Hệ thống tự chọn sẵn số người cần mời sao cho tổng khả năng nhận lời đủ bù số đơn vị máu đang thiếu:

$$\sum_{i=1}^{k} p_i \geq S \tag{3.4}$$

Công thức (3.4) này để xác định số người k cần mời, trong đó p_i là xác suất nhận lời của người thứ i trong danh sách và S là số đơn vị máu đang thiếu.

Sau khi nhân viên xác nhận, hệ thống kiểm tra lại điều kiện của từng người rồi gửi lời mời qua thông báo và email. Trong trường hợp chưa có mô hình hoặc AI bị tắt, danh sách được xếp theo cách chấm điểm luật như trước, đảm bảo chức năng luôn hoạt động.

3.2.3.2. Luồng xử lý AI dự báo nhu cầu sử dụng máu

Chức năng dự báo giúp bệnh viện biết trước nhóm máu và loại chế phẩm nào có nguy cơ thiếu trong 14 ngày tới, từ đó chủ động tổ chức đợt hiến hoặc kêu gọi người hiến. Trong luồng này, AI chỉ dự báo nhu cầu sử dụng, còn việc kết luận thiếu hay đủ được tính bằng quy tắc nghiệp vụ dựa trên tồn kho thực tế.

Dữ liệu lịch sử được lấy từ sổ kho, gồm các lần xuất máu cho người bệnh và các yêu cầu cần máu đã được xác minh. Các nghiệp vụ điều chuyển giữa bệnh viện và điều chỉnh kho không được tính là nhu cầu để tránh sai lệch. Từ dữ liệu này, hệ thống xây dựng các đặc trưng như nhu cầu của các ngày trước đó, trung bình 7 ngày và 28 ngày, ngày trong tuần, tháng trong năm và dịp Tết.

Mô hình XGBoost được sử dụng với hàm mục tiêu Poisson, phù hợp với dữ liệu dạng số đếm có nhiều ngày bằng 0. Phân phối Poisson mô tả số lần một sự kiện xảy ra trong một khoảng thời gian, nên phù hợp với số đơn vị máu sử dụng mỗi ngày; mô hình cũng luôn cho kết quả không âm, tránh trường hợp dự báo nhu cầu nhỏ hơn 0. Để đánh giá, hệ thống so sánh mô hình với cách tính trung bình 28 ngày bằng chỉ số sai số WAPE:

$$WAPE = \frac{\sum_i |y_i - \hat{y}_i|}{\sum_i y_i} \tag{3.5}$$

Công thức (3.5) này để tính sai số tương đối giữa nhu cầu thực tế và nhu cầu dự báo.

Trong đó y_i là nhu cầu thực tế và $\hat{y}_i$ là nhu cầu dự báo. Mô hình chỉ được sử dụng khi có sai số thấp hơn cách tính trung bình và không có xu hướng dự báo thiếu quá 5%, bởi dự báo thiếu có thể dẫn đến tình trạng thiếu máu thực tế mà hệ thống lại báo đủ.

Từ kết quả dự báo, lượng máu còn thiếu được tính theo công thức:

$$Thiếu = max\left(0, \sum_{h=1}^{14} \hat{y}_h + D - A\right) \quad (3.6)$$

Công thức (3.6) này để tính số đơn vị máu dự kiến thiếu trong 14 ngày tới, trong đó $\hat{y}_h$ là nhu cầu dự báo của ngày thứ h, D là nhu cầu đã lên kế hoạch và A là tồn kho khả dụng, bằng tồn kho thực tế trừ đi phần đang giữ chỗ cho bệnh viện khác.

Dựa trên số ngày lượng máu hiện có còn đủ dùng, hệ thống chia thành ba mức cảnh báo như Bảng 3.6.

Bảng 3.6. Các mức cảnh báo thiếu hụt

Mức cảnh báo	Điều kiện	Hành động gợi ý
Sắp thiếu	Còn đủ dùng dưới 7 ngày hoặc đang thiếu	Mời người hiến
Cần lên kế hoạch	Còn đủ dùng từ 7 đến 14 ngày	Tạo đợt hiến máu
Đủ dùng	Còn đủ dùng trên 14 ngày	Không cần hành động

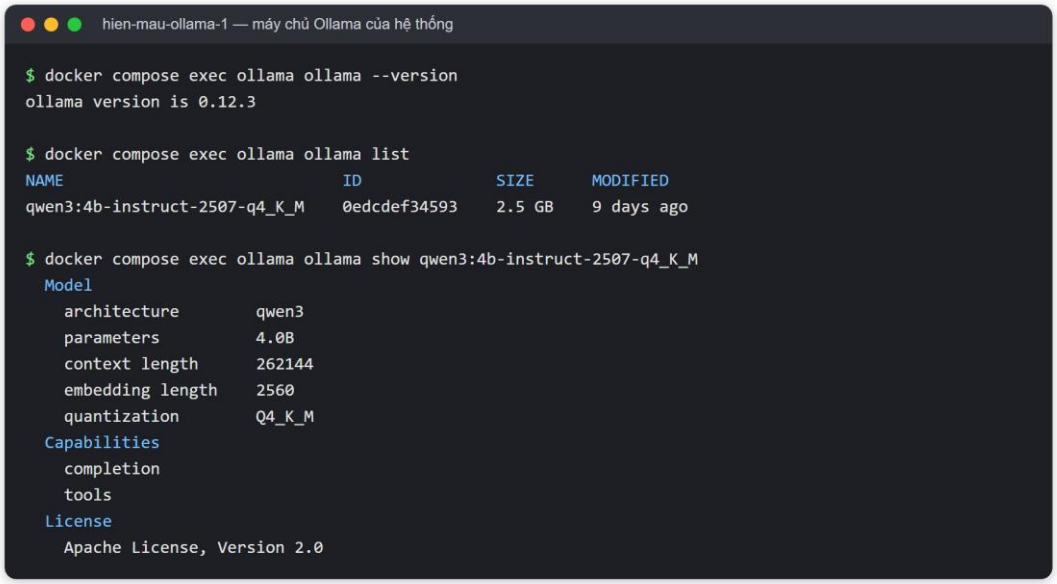
Quá trình dự báo được thực hiện tự động mỗi đêm và lưu kết quả vào bảng forecast_snapshots, nhờ đó trang dự báo chỉ cần đọc kết quả có sẵn mà không phải tính lại mỗi lần truy cập. Hằng ngày hệ thống so sánh kết quả dự báo với nhu cầu thực tế, chỉ huấn luyện lại mô hình khi có thêm dữ liệu mới hoặc sai số tăng lên, và tự động chuyển về cách tính trung bình 28 ngày nếu mô hình dự báo kém liên tục trong ba tuần.

3.2.3.3. Luồng xử lý AI chatbot tư vấn và hướng dẫn hiến máu

Chatbot đóng vai trò như một nhân viên tư vấn, giải đáp các câu hỏi về hiến máu và hướng dẫn người dùng sử dụng hệ thống bằng tiếng Việt tự nhiên. Chatbot sử dụng mô hình ngôn ngữ lớn mã nguồn mở Qwen3 được triển khai cục bộ thông qua nền tảng

Ollama, giúp hệ thống chủ động kiểm soát dữ liệu và không phụ thuộc vào dịch vụ AI bên ngoài.

Phiên bản được sử dụng là qwen3:4b-instruct-2507-q4_K_M với khoảng 4 tỷ tham số, được lượng tử hóa 4-bit (Q4_K_M) nên chỉ chiếm 2,5 GB và có thể chạy trên card đồ họa 4 GB. Mô hình hỗ trợ gọi công cụ (tools), nhờ đó có thể tra cứu dữ liệu của hệ thống trong quá trình trả lời, và được phát hành theo giấy phép Apache 2.0 cho phép sử dụng miễn phí. Thông tin mô hình trên máy chủ Ollama của hệ thống được thể hiện ở Hình 3.2.



Hình 3.2. Mô hình Qwen3 trên máy chủ Ollama của hệ thống

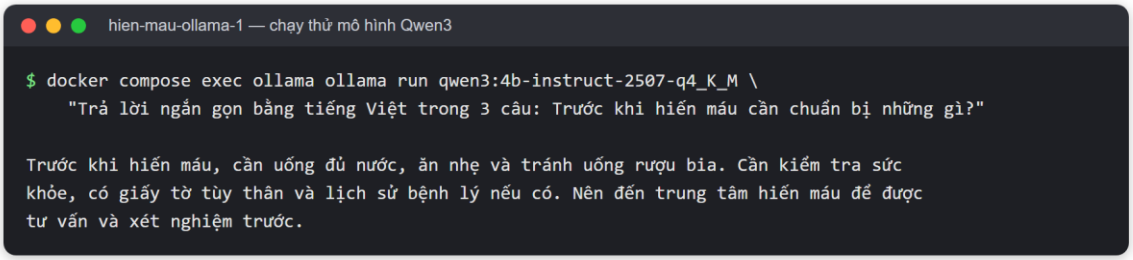
Khi người dùng gửi câu hỏi, hệ thống trước tiên kiểm tra các trường hợp đặc biệt cần trả lời ngay mà không gọi đến AI như Bảng 3.7.

Bảng 3.7. Các trường hợp chatbot trả lời ngay không gọi AI

STT	Loại câu hỏi	Ví dụ	Cách trả lời
1	Tình huống khẩn cấp	Đang chảy máu nhiều, bất tỉnh	Hướng dẫn gọi ngay 115
2	Hỏi thông tin của người khác	Số điện thoại của người hiến	Từ chối
3	Mua bán máu	Giá một túi máu	Từ chối
4	Câu lệnh phá quy tắc	“Bỏ qua hướng dẫn…”	Từ chối
5	Hỏi y khoa cá nhân	Đang dùng thuốc, có bệnh nền	Khuyên hỏi ý kiến bác sĩ

Với các câu hỏi thông thường, hệ thống áp dụng kỹ thuật RAG: tìm các tài liệu liên quan trong kho tri thức bằng thuật toán BM25 đã trình bày ở mục 3.2.2, đồng thời nếu câu hỏi liên quan đến dữ liệu của người dùng như đợt hiến gần nhất, thời điểm được hiến lại hay trạng thái đơn đăng ký thì hệ thống tra cứu dữ liệu tương ứng. Các công cụ tra cứu này chỉ được phép đọc dữ liệu của chính người đang đăng nhập và không trả về thông tin nhạy cảm như tên bệnh nhân hay số điện thoại. Thông tin tìm được cùng với các quy tắc ràng buộc được đưa vào ngữ cảnh gửi tới mô hình, yêu cầu mô hình chỉ trả lời dựa trên dữ liệu được cung cấp.

Hình 3.3 minh họa mô hình Qwen3 chạy trên máy chủ Ollama trả lời một câu hỏi bằng tiếng Việt khi chưa có ngữ cảnh của hệ thống. Trong ứng dụng, câu hỏi được bổ sung tài liệu đã duyệt và dữ liệu tra cứu trước khi gửi tới mô hình, vì vậy câu trả lời bám sát nội dung kho tri thức và có kèm nguồn tham khảo.



Hình 3.3. Chạy thử mô hình Qwen3 trên máy chủ Ollama

Trước khi gửi câu trả lời cho người dùng, hệ thống kiểm tra lại nội dung do AI tạo ra: các mã đơn hay mã yêu cầu xuất hiện trong câu trả lời phải có trong dữ liệu đã tra cứu, nếu không sẽ bị coi là thông tin bịa; câu trả lời không được lẫn ngôn ngữ khác; và mọi câu khẳng định người dùng đủ điều kiện hiến máu đều được bổ sung lời nhắc rằng bác sĩ khám sàng lọc mới là người quyết định.

Hệ thống được thiết kế với cơ chế fallback: trong trường hợp mô hình AI gặp lỗi, phản hồi quá chậm hoặc câu trả lời không vượt qua bước kiểm tra, chatbot tự động chuyển sang chế độ trả lời theo từ khóa, sử dụng cùng các tài liệu và dữ liệu đã tra cứu để tạo câu trả lời, giúp người dùng luôn nhận được phản hồi. Câu trả lời được hiển thị dần theo thời gian thực và kèm theo nguồn tài liệu tham khảo.

Lịch sử hội thoại của người dùng đã đăng nhập được lưu trong các bảng chat_conversations và chat_messages, chỉ chủ tài khoản được xem và tự động xóa sau 30 ngày. Để bảo vệ quyền riêng tư, nhật ký hệ thống chỉ ghi nhận loại câu hỏi và cách

trả lời mà không lưu nội dung câu hỏi. Ngoài ra, mỗi người dùng chỉ được gửi tối đa 20 câu hỏi trong 5 phút nhằm tránh lạm dụng và đảm bảo hiệu năng hệ thống.